

# 硕士学位论文

(学术学位论文)

面向代码质量评估的变更影响分析方法研究

**RESEARCH ON CHANGE IMPACT  
ANALYSIS METHODS FOR CODE  
QUALITY ASSESSMENT**

李美娜

哈尔滨工业大学

2024 年 12 月

国内图书分类号: TM301.2  
国际图书分类号: 62-5

学校代码: 10213  
密级: 公开

## 硕士学位论文

# 面向代码质量评估的变更影响分析方法研究

硕士研究生: 李美娜

导师: 苏小红教授

申请学位: 工学硕士

学科或类别:

所在单位: 计算学部

答辩日期: 2024 年 12 月

授予学位单位: 哈尔滨工业大学

Classified Index: TM301.2

U.D.C: 62-5

Dissertation for the Master's Degree

# **RESEARCH ON CHANGE IMPACT ANALYSIS METHODS FOR CODE QUALITY ASSESSMENT**

<b>Candidate:</b>	Li Meina
<b>Supervisor:</b>	Prof. Su Xiaohong
<b>Academic Degree Applied for:</b>	Master of Engineering
<b>Specialty:</b>	Software Engineering
<b>Affiliation:</b>	School of Computer Science
<b>Date of Defence:</b>	December, 2017
<b>Degree-Confering-Institution:</b>	Harbin Institute of Technology

## 摘 要

摘要的字数（以汉字计），硕士学位论文一般为 500 ~ 1000 字，

关键词：代码质量分析；变更影响；代码审查

## Abstract

An abstract

**Keywords:** code quality analysis, change impact, code review

# 目 录

摘 要 .....	I
Abstract .....	II
第 1 章 绪论 .....	1
1.1 课题研究的背景和意义.....	1
1.2 国内外研究现状及分析.....	1
1.2.1 国内外研究现状 .....	1
1.2.2 代码变更影响分析方法的的国内外研究现状 .....	1
1.2.3 题目 .....	1
1.3 本文的主要研究内容以及各章节安排.....	1
1.3.1 主要研究内容 .....	1
1.3.2 章节安排 .....	1
第 2 章 代码中间表示提取与分析特征提取 .....	2
2.1 引言 .....	2
2.2 基于 clang 的抽象语法树生成方法 .....	2
2.3 方法调用链提取与分析.....	3
2.4 全局变量定义-使用链提取与分析 .....	4
2.5 基于方法特征的代码度量提取 .....	5
2.5.1 基于内聚度缺乏度的内聚性分析 .....	6
2.5.2 基于连通性的内聚性分析 .....	7
2.5.3 方法间耦合性分析 .....	7
2.5.4 方法扇入扇出度量分析 .....	8
2.6 本章小节.....	9
第 3 章 变更影响分析方法 .....	10
3.1 引言 .....	10
3.2 基于依赖关系闭包的变更影响分析 .....	10
3.3 基于代码克隆的变更影响分析 .....	11
3.3.1 代码分段及代码指纹提取 .....	11
3.3.2 基于 ClaSP 算法的代码克隆检测方法 .....	11

3.4 基于数据挖掘的变更影响分析 .....	11
3.4.1 代码变更历史提取 .....	11
3.4.2 基于频繁模式挖掘的变更影响关系提取 .....	12
3.5 基于深度学习的变更影响分析 .....	12
3.5.1 数据集的采集与预处理 .....	13
3.5.2 基于 codebert 的变更影响预测 .....	13
3.6 本章小节 .....	14
第 4 章 代码审查图生成 .....	15
4.1 引言 .....	15
4.2 基于方法功能标签的方法聚类 .....	15
4.2.1 基于大语言模型的方法功能标签生成 .....	15
4.2.2 基于功能标签的方法聚类 .....	15
4.3 代码审查图 .....	15
4.3.1 代码审查图构建 .....	15
4.3.2 代码审查图可视化 .....	15
4.4 本章小节 .....	15
结 论 .....	16
参考文献 .....	17
哈尔滨工业大学学位论文原创性声明和使用权限 .....	18
致 谢 .....	19

## 第 1 章 绪论

### 1.1 课题研究的背景和意义

课题研究的背景和意义

### 1.2 国内外研究现状及分析

#### 1.2.1 国内外研究现状

#### 1.2.2 代码变更影响分析方法的的国内外研究现状

#### 1.2.3 题目

### 1.3 本文的主要研究内容以及各章节安排

#### 1.3.1 主要研究内容

#### 1.3.2 章节安排



## 第 2 章 代码中间表示提取与分析特征提取

### 2.1 引言

### 2.2 基于 clang 的抽象语法树生成方法

抽象语法树 (Abstracted Syntax Tree, AST) 是一种用来表现编程语言构造的树状结构, 它把代码的语法结构以树形的方式进行了抽象化描述。在这个树形结构中, 每一个节点都对应着代码中的某个元素, 比如变量声明、语句或者是表达式等。从这棵树的根节点出发, 代码逐步被拆解成更小的部分, 直到最终到达叶节点, 这些叶节点代表了代码中最基本的元素, 如操作符或变量等。在这棵树中, 节点之间的连接仅表明了它们之间的层级关系, 即父节点与子节点的关系。通过这样的结构, AST 能够清晰地展示出代码的层次和结构, 为编译器或其他工具分析和处理代码提供便利。

Clang 是由苹果公司发起的支持 C、C++、Objective-C 和 Objective-C++ 语言的编译器前端, 负责对代码进行词法分析、语法分析和语义分析, 对程序代码的分析和理解至关重要 [7]。词法分析通过识别 Token 将程序代码分解成基本单元。语法分析在此基础上识别程序的语法结构, 构造抽象语法树。语义分析消除语义模糊, 生成属性信息, 让计算机生成目标代码。libclang 是 Clang 编译器的一个重要组成部分, 提供了一套用于解析源代码的程序接口。这些程序接口允许开发者在自己的项目中使用 Clang 的强大语言解析和代码分析功能 [8]。为提取代码中的调用和依赖关系, 本课题使用了 libclang 生成 AST 的能力, 为后续进一步分析提供基础。

如图 2-2 所示, 举例说明 clang 的使用。这里定义了一个简单的 C 语言文件, 定义了两个函数和一个全局变量, 主函数用于计算两个数的和。

这段代码由 Clang 解析生成抽象语法树后, 得到的树结构如下图 2-3 所示。

在 libclang 解析得到的抽象语法树中, 游标 (cursor) 是一个核心概念, 它作为一个指针或引用存在, 每个 cursor 都与 AST 中的一个特定节点相对应, 表示了源代码中的一个结构元素。通过操作 cursor, 可以遍历整个 AST, 访问和分析代码中的各种元素, 如获取变量的类型、函数的参数列表、类的成员等。libclang 提供了一系列 API 函数来操作 cursor, 例如: 遍历 AST 中的 cursor、获取 cursor

```
1  #include <stdio.h>
2
3  int globalVar = 10;
4
5  int addNumbers(int a, int b) {
6      return a + b;
7  }
8
9  void main() {
10     int num1 = 5;
11     int num2 = 7;
12     int sum = addNumbers(num1, num2);
13     printf("Sum of %d and %d is: %d\n", num1, num2, sum);
14 }
```

图 2-1 示例代码

的类型（如是否为方法定义、变量定义、变量引用等）、获取 **cursor** 所代表的源代码元素的名称、类型、位置等信息、获取 **cursor** 的父节点或子节点等。这里我们通过操作游标，遍历 **AST**，获取整个 **AST** 的结构。

**Clang** 定义了一套节点类型标识。**AST** 的顶层节点类型是 **Translation\_Unit** 标签，表示一个翻译单元，对 **AST** 树的遍历，实际上就是遍历整个 **Translation\_Unit**。**Function\_Decl** 指的是函数定义，在 **clang** 中是不区分函数声明和函数定义的，统一用 **Function\_Decl** 来标识，两个区分主要看是否有函数体，在 **libclang** 中提供了程序接口供我们调用判断。**Parm\_Decl** 是参数节点，上面的例子中，函数 **addNumbers** 有两个参数 **a** 和 **b**。**CompoundStmt** 代表大括号，函数实现、**struct**、**enum**、**for** 的 **body** 等一般用此标签包起来。**DeclStmt** 是定义语句，里边可能有 **VarDecl** 等类型的定义，**VarDecl** 是对变量的定义。**CallExpr** 标签表示函数调用 **Expr**，子节点有调用的参数列表。**ReturnStmt** 表示返回语句。

## 2.3 方法调用链提取与分析

代码项目中的方法之间的调用关系是本课题中的分析基础。在使用 **Clang** 提取到 **AST** 后，遍历整棵树来提取方法之间的调用关系。这部分我们重点关注 **AST** 上的方法节点，以及节点内部的调用节点。

对 **AST** 的遍历主要分为两次，第一次遍历获取所有的方法定义。首先提取所有的 **FUNCTION\_DECL** 节点，它表示了对方法的定义，在该节点中可提取方法签名。在 **FUNCTION\_DECL** 节点下，提取子节点 **PARM\_DECL**，该节点表示方法的参数列表，在该节点中可提取参数名称和参数类型等参数相关信息。然后提取 **FUNCTION\_DECL** 节点的子节点 **VarDecl**，该节点表示在该方法内定义的局部变量。在对方法进行分析时，我们本身不关心方法的内部实现，但是由于在 **C/c++** 语言中，存在局部变量可以和全局变量重名的情况，在这里提取方

```

CursorKind.TRANSLATION_UNIT resources/template.c
| CursorKind.VAR_DECL globalVar
| | CursorKind.INTEGER_LITERAL
| CursorKind.FUNCTION_DECL addNumbers
| | CursorKind.PARM_DECL a
| | CursorKind.PARM_DECL b
| | CursorKind.COMPOUND_STMT
| | | CursorKind.RETURN_STMT
| | | | CursorKind.BINARY_OPERATOR
| | | | | CursorKind.UNEXPOSED_EXPR a
| | | | | CursorKind.DECL_REF_EXPR a
| | | | | CursorKind.UNEXPOSED_EXPR b
| | | | | CursorKind.DECL_REF_EXPR b
| CursorKind.FUNCTION_DECL main
| | CursorKind.COMPOUND_STMT
| | | CursorKind.DECL_STMT
| | | | CursorKind.VAR_DECL num1
| | | | | CursorKind.INTEGER_LITERAL
| | | | CursorKind.DECL_STMT
| | | | | CursorKind.VAR_DECL num2
| | | | | CursorKind.INTEGER_LITERAL
| | | | CursorKind.DECL_STMT
| | | | | CursorKind.VAR_DECL sum
| | | | | CursorKind.CALL_EXPR addNumbers
| | | | | | CursorKind.UNEXPOSED_EXPR addNumbers
| | | | | | | CursorKind.DECL_REF_EXPR addNumbers
| | | | | | | CursorKind.UNEXPOSED_EXPR num1
| | | | | | | | CursorKind.DECL_REF_EXPR num1
| | | | | | | | CursorKind.UNEXPOSED_EXPR num2
| | | | | | | | CursorKind.DECL_REF_EXPR num2
| | | | CursorKind.CALL_EXPR printf
| | | | | CursorKind.UNEXPOSED_EXPR printf
| | | | | | CursorKind.DECL_REF_EXPR printf
| | | | | CursorKind.UNEXPOSED_EXPR
| | | | | | CursorKind.UNEXPOSED_EXPR
| | | | | | | CursorKind.STRING_LITERAL "Sum of %d and %d is: %d\n"
| | | | | | | CursorKind.UNEXPOSED_EXPR num1
| | | | | | | | CursorKind.DECL_REF_EXPR num1
| | | | | | | | CursorKind.UNEXPOSED_EXPR num2
| | | | | | | | | CursorKind.DECL_REF_EXPR num2
| | | | | | | | | CursorKind.UNEXPOSED_EXPR sum
| | | | | | | | | | CursorKind.DECL_REF_EXPR sum

```

图 2-2 示例代码对应的抽象语法树结构

法内定义的局部变量，方便后续在提取全局变量时，对变量进行作用域的判断。除此之外，还需提取整个方法的 **token** 序列，所在文件以及作用域。

第二次遍历的主要目的是提取方法之间的调用关系。提取 **FUNCTION\_DECLCALL\_EXPR - 1**

分析结束后，将会获得每个方法的方法调用链，对应于一个方法摘要表，包括项目代码中所有的方法和方法之间的调用关系，除此之外还包括方法的参数表、方法主体和所在文件等其他信息。

## 2.4 全局变量定义-使用链提取与分析

全局变量定义-引用链的提取和方法的定义和调用提取是类似的。对 **AST** 的遍历主要也分为两次。具体流程如图第一次遍历获取所有的方法定义。首先提取所有的 **VAR\_DECLASTC/c++staticMap < Name, globalVar >**

第二次遍历的主要目的是提取全局变量的引用点。在方法节点子树中搜索 DECL\_REF\_EXPR 节点，它表示对变量的引用，这里首先判断被引用的变量是否是局部变量，根据函数摘要表中该函数的记录可以判断，如果是则直接返回，如果不是，则证明使用的是全局变量，这里首先对该变量名在哈希表中进行查找，如果查找到了，说明是在该文件中定义的全局变量，以节省检索时长，同时能够保证如果是 static 的全局变量的准确性。如果没有查找找到，则说明引用了别的文件中定义的全局函数，则就在哈希表中进行遍历查找，记录该全局变量被引用的方法。具体计算流程如图 2-3 所示。

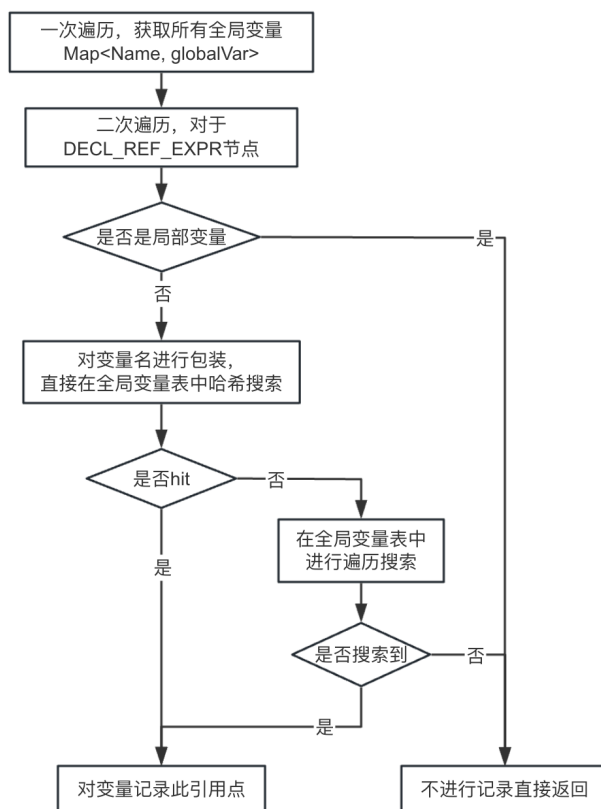


图 2-3 示例代码对应的抽象语法树结构

分析结束后，将会获得每个全局变量的定义-引用链，对应于一个全局变量信息表，包括项目代码中所有的全局变量和变量的引用点，除此之外还包括全局变量的类型、作用域和所在文件等其他信息。

## 2.5 基于方法特征的代码度量提取

代码内聚度和代码耦合度是衡量软件设计质量的两个核心指标，它们直接反映了代码质量。代码内聚度指的是模块（如函数、类或组件）内部元素之间的相关性。高内聚度意味着模块内的所有元素都紧密地围绕着一个单一的、明

确的功能，代码更容易理解和维护 [9]。代码的耦合性则描述了模块之间的相互依赖。低耦合度意味着模块之间的依赖关系最小化，每个模块都可以独立地执行其功能，而不需要过多地依赖其他模块。低耦合度的代码更容易测试和维护 [10]。

基于方法摘要和全局变量信息表，我们计算如下代码度量，用于分析代码质量。

### 2.5.1 基于内聚度缺乏度的内聚性分析

**LCOM (Lack of Cohesion in Methods)** 系列指标用于衡量模块的内聚度。本课题中面向对象语言以类为研究范围进行计算内聚度，非面向对象的语言以文件为研究范围进行计算，类中的成员属性对应文件中的全局变量，类中的成员方法对应文件中定义的方法。**LCOM** 指标的核心思想是测量一个类中方法对实例变量（属性）的共享程度。不同版本的 **LCOM** 有着不同的计算方法和含义。这里我们一共计算以下四个指标：

(1) **LCOM1**，含义是不引用相同字段的方法对数目 [11]。

其中，**P** 是不共享实例变量的方法对的数量，**Q** 是共享实例变量的方法对的数量。如果 **LCOM1** 的结果为负数，则被置为 0。在计算时，对于每个文件首先构建方法耦合图 (**method coupling graph**)，将提取到的方法作为图中节点，对方法两两进行判断，如果两个节点都引用相同的字段，则它们之间用一条无向边连接，按如下公式计算，其中 **n** 是文件中的方法总数，**e** 是图中的实际边数，即图中可能的最大边数减去实际的边数，得到的值即为 **LCOM1**

(2) **LCOM2**，含义是不引用相同字段方法与引用相同字段方法对数之差 [12]。**LCOM2** 相比于 **LCOM1**，考虑到了类中所有方法和变量的相互作用，其计算公式是：其中， $n$  是类中属性的数量， $a_i$  是访问属性  $i$  的方法数量。在计算时，首先构建方法属性图 (**method-attribute graph**)，将提取到的方法和全局变量作为图中节点。如果方法引用了变量，则有一条有向边从方法节点指向属性变量，计算公式如下，

其中  $n$  为方法数， $a$  为变量数。假设  $e$  是图中的实际边数，得到的值即为 **LCOM2**。

(3) **LCOM3**，含义是以方法为顶点，两方法引用相同字段则有边构成的无向图的连通分支数 [12]。**LCOM3** 是对 **LCOM2** 的进一步改进，其计算公式是：其中， $m$  是类中方法的数量， $a$  是类中属性的数量， $a_i$  是第  $i$  个方法访问的属性数量， $a_{ij}$  是被第  $i$  个方法访问的属性数量。**LCOM3** 试图通过分析方法和属性之

间的关系来提供更细致的内聚度度量。

计算时的公式如下，基于上述计算出的 LCOM2 指标可以快速地计算出 LCOM3

(4) LCOM4, 含义是以方法为顶点, 两方法引用相同字段或有调用关系则有边构成无向图的连通分支数 [13]。计算时, 构建方法耦合图, 节点是方法。如果两个节点都引用相同的字段, 则它们之间用一条无向边连接, 除此之外, 如果两个节点有调用关系, 则也用一条无向边将它们连接。根据深度搜索的方式, 计算图中的连通分支数, 得到的值即

### 2.5.2 基于连通性的内聚性分析

(1)TCC (Tight Class Cohesion) 和 LCC (Loose Class Cohesion) 是两种用于衡量类内聚度的指标, 它们主要关注于类中方法之间的连通关系。这两个指标的核心思想是通过分析类中方法如何相互作用以及如何访问共同资源(如类级变量)来评估类的内聚度。(1) TCC, 含义是有关系方法对数/方法对总数 [14]。TCC 关注于类中方法之间的“直接连接”。如果两个方法直接共享访问同一个类级变量, 则认为这两个方法是直接连接的。计算时, 对于每个文件首先构建方法耦合图, 对方法两两进行判断, 如果两个节点都引用相同的字段, 则它们之间用一条无向边连接, 按如下公式计算, 其中  $n$  是文件中的方法总数,  $e$  是图中的实际边数

(2) LCC, 基于方法间接引用共同字段关系的传递闭包计算 [14]。LCC 除了考虑直接连接的方法对外, 还包括了间接连接的方法对。如果两个方法不是直接连接, 但可以通过一系列的方法调用来连接, 则认为它们是间接连接的。LCC 的值基于类中直接或间接连接的方法对占所有可能方法对的比例来计算。因此, LCC 的值通常不低于 TCC 的值, 并且提供了一个更宽泛的类内聚度视角。计算时, 对于每个文件首先构建方法耦合图, 对方法两两进行判断, 如果两个节点都引用相同的字段, 则它们之间用一条无向边连接表示直接连接, 如果方法之间有调用, 则也将方法进行连接, 并连接当前节点和调用节点的所有邻居节点。按如下公式计算, 其中  $n$  是文件中的方法总数,  $e$  是图中的直接连接边,  $\bar{e}$  是除直接连接边的边数。

### 2.5.3 方法间耦合性分析

耦合是软件结构中各模块之间相互连接的一种度量, 根据耦合程度可以分为 6 种, 耦合度依次变低。

内容耦合是指一个模块可以直接访问另一个模块的内部数据，由于我们分析的是方法粒度的耦合关系，而在方法之间并不存在此种情况，故不关注这种耦合关系。

公共耦合是指多个模块都访问同一个公共数据环境，公共数据环境例如全局数据结构、内存公共覆盖区等。在提取到的全局变量表中，针对复杂类型的数据结构，如结构体、数组结构等，它们的引用点所在的方法，两两之间都存在此种公共耦合关系。

外部耦合指多个模块访问同一个全局简单变量。与公共耦合类似，在提取的全局变量表中，对于基本类型的全局变量的引用点所在的方法，两两之间都存在此种外部耦合关系。

控制耦合指模块之间传递信息中包含用于控制模块内部的信息。在提取到的方法摘要表中，遍历方法，如果该方法调用其他方法时，对应方法的参数列表中有变量决定了被调用方法中的计算流程，则方法之间存在控制耦合关系。

标记耦合指通过参数表传递数据结构信息，调用时传递的是数据结构。在方法摘要表中，我们提取了方法的参数列表，包括参数名和参数类型，根据参数类型，可以确定参数表中是否包含复杂类型。除此之外，在方法的调用表中，我们也提取了方法调用的函数，结合这两个信息，即可确定两个方法是否存在着标记耦合关系。

数据耦合指通过参数表传递简单数据。与标记耦合类似，根据参数类型可以确定参数是否全部为基本类型，结合方法调用表，即可确定两个方法是否存在数据耦合。

#### 2.5.4 方法扇入扇出度量分析

函数的扇入 (Fan-in) 和扇出 (Fan-out) 是软件工程中用于衡量函数复杂性和模块间依赖关系的两个指标。

扇入是指调用某个函数的不同函数的数量。它表示了一个函数对其他函数的依赖程度。扇入值较高的函数通常被认为是重要的或核心的，因为它们被多个其他函数依赖。高扇入值可能意味着该函数执行了一个基础或共享的任务。

扇出是指某个函数直接调用的不同函数的数量。它表示了一个函数对其他函数的影响程度。扇出值较高的函数可能更复杂，因为它们需要管理和协调更多的函数调用。高扇出值可能意味着该函数具有较高的责任度，且可能更难以理解和维护。

对于提取到的方法摘要表，遍历每一个方法，统计其调用方法的数量即可




图 2-4 扇入扇出示例图

计算出该方法的扇出值，再以该方法名在方法摘要表中搜索调用了该方法的方法，统计总数，得到的值即为扇入值。

## 2.6 本章小节



## 第3章 变更影响分析方法

### 3.1 引言

方法之间的变更影响的类型可以分为以下三种类型：

(1) 有直接调用关系这种变更影响关系是显而易见的。比如方法 `funcA` 调用了方法 `funcB`，那么当 `funcB` 的方法签名有所变化时，调用它的方法必须对应地修改代码才能正常调用，否则会调用不成功，甚至直接发生编译错误。

(2) 共同调用另一个方法如当 `funcA` 和 `funcC` 同时调用了方法 `funcB` 时，`funcA` 和 `funcC` 之间会有变更影响关系。这种变更影响关系实际上是类型 1 的扩展，这种情况通常是 `funcB` 的更改引起了 `funcA` 和 `funcC` 的同时更改。

(3) 逻辑上存在变更影响关系这种变更影响关系中，方法之间虽然没有直接的调用关系，也不共同调用某个方法，但它们的实现逻辑或者所操作的数据之间存在某种隐含的关联。这种关系可能是由于它们共同维护某个数据的一致性、共享某些资源或者它们的输出和输入之间存在某种预期的联系。因此，当其中一个方法发生变化时，可能会间接影响到其他方法的行为或结果，即使这种影响在代码的静态结构中不直接可见。

### 3.2 基于依赖关系闭包的变更影响分析

在代码变更影响关系分析中，依赖关系传递闭包分析是一种用来预测代码变更可能影响到的其他部分的技术 [15]。这种方法依赖于对代码中各个元素之间依赖关系的深入分析，通过这些依赖关系的传递来识别受影响的代码方法。这种变更影响关系是后续进行模块化分析的基础。

首先识别直接依赖关系。包括函数调用、变量引用等。此前提取到的方法摘要表和全局变量信息表已经包含了这种直接依赖关系。接下来将依赖关系表示为一个有向图，其中节点代表代码中的元素，包括方法、全局变量，有向边代表依赖关系。这个依赖图是分析代码变更影响的基础。对于依赖图中的每个节点，计算其传递闭包。传递闭包是指从该节点出发，通过依赖关系可以直接或间接到达的所有节点的集合。这一步骤通过图深度优先搜索来实现。

对于图中的所有方法节点进行变更影响分析，我们假设该节点有变更，计算传递闭包后，得到的方法集合即为与当前方法有变更影响关系的方法。

以图 2-5 为例，在这个例子中，一共有 4 个方法，其中方法 funcA 调用了 funcB 和 funcD，funcB 调用了 funcC。在对 funcC 进行变更影响分析时，会直接影响到 funcB，根据依赖关系闭包，会间接影响到 funcA。所以与 funcC 有变更影响关系的方法集合为 funcB, funcA。

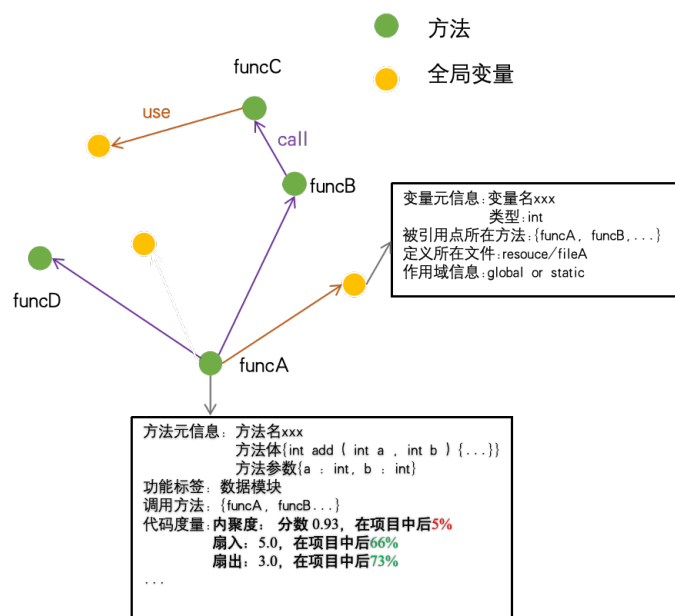


图 3-1 依赖关系示例

### 3.3 基于代码克隆的变更影响分析

#### 3.3.1 代码分段及代码指纹提取

#### 3.3.2 基于 ClaSP 算法的代码克隆检测方法

### 3.4 基于数据挖掘的变更影响分析

#### 3.4.1 代码变更历史提取

基于依赖关系闭包的方法可以识别方法之间浅层的变更影响关系，主要针对的是语法和依赖关系层面，而无法抽取更深层的关系，因此设计了基于数据挖掘技术的变更影响分析方法。本方法主要针对拥有代码变更历史记录的软件项目。其主要理论是认为在代码变更历史中，频繁出现同时更改的方法对是存在着一定的变更影响关系的。这一过程可以分为以下几个步骤：

这里为方便分析代码变更历史，主要分析对象为 git 项目。首先是收集项目的代码库及其变更历史记录。然后，提取项目中的所有提交 (commit)，每个提交可能包含多个更改文件。对于标记为“修改”的文件，提取所有变化的代码

行，并定位这些代码行在源代码中的方法，进而提取该方法体。收集每个提交中所有变更的函数，形成一个与该提交相关的变更函数列表。

### 3.4.2 基于频繁模式挖掘的变更影响关系提取

接下来，基于数据挖掘中的频繁模式挖掘理论，识别可能存在变更影响关系的函数对。频繁模式指的是在数据集中经常一起出现的项目或特征组合，而频繁项集是频繁模式的具体表现形式。频繁项集是指在数据集中经常同时出现的一组项，如果一个项集的支持度（即该项集出现的记录占总记录数的比例）超过了预先定义的最小支持度阈值，则认为该项集是频繁的。在分析提交时，针对一个方法 A，记录其在所有提交记录中出现的次数为 N，而在这些提交中，统计其他出现的方法次数 M，如对方法 B，记录其出现的次数为 M。如果  $M/N$  的值为设定的阈值 = 1，则认为方法对 (A, B) 有变更影响关系。换言之，这意味着每当 A 出现时，B 也必然出现，方法对 (A, B) 每次更改都为同时更改。

遍历项目变更历史，抽取出有变更影响关系的方法对，认为它们之间存在着变更影响关系

对收集到的数据进行分析，这里以真实项目中挖掘到的方法对为例，如图 2-6 中所示，这个项目是 kafka 的一个 C/C++ 客户端。方法一的主要功能是在 Kafka 模拟环境中按照一定的规则生成 Producer ID，而方法二的功能是检查一个 Producer ID 是否有效。当涉及检查的逻辑时，往往需要考虑到它是如何被创建和分配的。在这个例子中需要确保 ID 的创建逻辑与检查逻辑一致，才能确保检查是正确的。这个方法中，对于要检查的 Producer ID，首先会判断事务 ID，然后再检查 epoch，逻辑与创建 ID 是形成对应的。考虑修改的行为，如果对于 Producer ID 的创建和分配逻辑进行了修改，那么通常需要同时修改 Producer ID 检查逻辑，以确保两者保持一致。否则，如果创建和分配逻辑发生了变化，而检查逻辑没有相应地进行调整，就可能导致检查逻辑无法正确地验证新生成的 Producer ID，从而引入错误和不一致性。

经过分析可以看出，通过数据挖掘方法得到的具有变更关系的方法对，是具有一定的准确性的，并且可以弥补静态分析的不足。

## 3.5 基于深度学习的变更影响分析

当项目代码有丰富的变更历史时，可以根据数据挖掘的方式，抽取具有变更影响关系的方法对，但是当只有项目源代码时，则只能根据静态分析的方式分析。本课题将数据挖掘得到的数据作为数据集，训练深度学习模型，将模型

```

rd_kafka_pid_t rd_kafka_mock_pid_new(rd_kafka_mock_cluster_t *mcluster,
                                     const rd_kafkap_str_t *TransactionalId) {
    //计算长度, 分配内存
    size_t tidlen = TransactionalId ? RD_KAFKAP_STR_LEN(TransactionalId) : 0;
    rd_kafka_mock_pid_t *mpid = rd_malloc(sizeof(*mpid) + tidlen);
    rd_kafka_pid_t ret;
    //生成一个随机的 Producer ID、设定epoch
    mpid->pid.id = rd_jitter(1, 900000) * 1000;
    mpid->pid.epoch = 0;
    //将事务ID拷贝到pid里
    if (tidlen > 0) memcpy(mpid->TransactionalId, TransactionalId->str, tidlen);
    mpid->TransactionalId[tidlen] = '\0';
    //新产生的 Producer ID 添加到模拟集群中的 pid 列表
    rd_list_add(&mcluster->pids, mpid);
    ret = mpid->pid;
    //返回
    return ret;
}

rd_kafka_resp_err_t rd_kafka_mock_pid_check(rd_kafka_mock_cluster_t *mcluster,
                                             const rd_kafkap_str_t *TransactionalId,
                                             const rd_kafka_pid_t check_pid) {
    rd_kafka_mock_pid_t *mpid;
    rd_kafka_resp_err_t err = RD_KAFKA_RESP_ERR_NO_ERROR;
    //检查TID、epoch
    err = rd_kafka_mock_pid_find(mcluster, TransactionalId, check_pid, &mpid);
    if (!err && check_pid.epoch != mpid->pid.epoch) err = RD_KAFKA_RESP_ERR_INVALID_PRODUCER_EPOCH;
    //检查失败
    if (unlikely(err)) rd_kafka_dbg(mcluster->rk, MOCK, ...);
    return err;
}

```

图 3-2 逻辑上有变更影响关系的方法对示例

用于对方法对的变更影响关系预测，以弥补静态分析方法的不足。

### 3.5.1 数据集的采集与预处理

根据数据挖掘的变更影响关系分析的方法，可以提取到具有频繁同时更改的方法对，将这种方法对作为数据集的正例进行收集，然后对方法进行随机取样，作为数据集的负例收集。

这里我们主要以表 2-1 中的 github 项目为基础收集数据集。选择这几个项目的原因是它们的收藏数均在千以上，说明这些项目在开源社区中有着一定的影响力，使用比较广泛。除此之外，这些项目社区比较活跃，还在不断更新迭代过程中，所以能提供较为丰富的变更历史，以供我们分析。

### 3.5.2 基于 codebert 的变更影响预测

在进行学习模型的训练时，考虑到对代码的理解性，采用 CodeBERT 作为核心的代码表示学习模型。首先，将两个方法体分别输入到模型中，通过模型的处理，得到两个函数体各自的嵌入表示，分别记为 s1 和 s2。接着将这两个向量表示进行拼接，形成合并后的向量表示。此合并向量随后被送入一个由两层组成的多层感知机（MLP）中进行进一步的处理。在这个过程中，模型通过学习，尝试捕捉函数体之间的深层次关系。最终，将模型的输出与真实标签之间做交叉熵损失来进行优化，以此来调整模型的参数，使模型能够更准确地理解和表示代码之间的关系。

实验结果如表 2-2 所示。实验使用的数据集总共 6000 对左右，按照训练、验证、测试集为 6:2:2，分别训练了 codebert 系列的两个网络 CodeBERTa-small-v1

和 `codebert-base-mlm`，具体结果如下：

从总体上来看，两个模型的性能均表现出色，但深入分析召回率（`recall`）和精确率（`precision`）时，可以发现两个模型各有所长。

`CodeBERTa-small-v1` 模型更加重视精确率，强调预测出的正例的真实性和准确性。这意味着它在确保预测结果的准确性方面做得很好，但这种方法可能会导致一些正确的情况被漏掉，即存在漏报的情况。由于“`small`”模型的规模较小，参数数量较少，这可能会使得模型在训练过程中更容易发生过拟合现象。

另一方面，`CodeBERT-base-mlm` 模型更加注重召回率，致力于捕捉尽可能多的正样本。这种策略虽然能够覆盖更多的正例，但在这个过程中，也可能会引入一些误报，即将一些实际上是负例的情况错误地判定为正例。大型模型由于具备更强的泛化能力，通常能够更好地适应新的数据集。因此，为了获得更好的泛化性能，它们通常会牺牲一定的精确率。

### 3.6 本章小节

## 第 4 章 代码审查图生成

### 4.1 引言

对整个项目的分析结果将以代码审查图的方式展示给用户。其中图的节点是代码元素，包括方法和全局变量，方法和方法以及方法和全局变量之间的关系将以边的形式进行展示。

### 4.2 基于方法功能标签的方法聚类

#### 4.2.1 基于大语言模型的方法功能标签生成

#### 4.2.2 基于功能标签的方法聚类

### 4.3 代码审查图

#### 4.3.1 代码审查图构建

#### 4.3.2 代码审查图可视化

图形可视化方案基于开源项目 **G6**，构建并展示最终的代码审查图。**G6** 是一个图形可视化引擎，它提供了绘制、布局、分析、交互、动画等全方位的图形可视化基础功能。在图形的节点与边被计算出后，将这些数据以 **JSON** 格式组织起来，这样可以让 **G6** 加载这些远程数据源进行展示，同时也实现了计算逻辑与图形可视化的有效分离。

如图 2-8 所示，目前实现了节点的分类、设置节点属性，以及边的分类、设置边信息等关键功能。为了提升交互体验，还增加了鼠标悬停时即可查看节点或边信息的便捷功能。

### 4.4 本章小节

## 结 论

学位论文的结论作为论文正文的最后一章单独排写，但不加章标题序号。

结论应是作者在学位论文研究过程中所取得的创新性成果的概要总结，不能与摘要混为一谈。博士学位论文结论应包括论文的主要结果、创新点、展望三部分，在结论中应概括论文的核心观点，明确、客观地指出本研究内容的创新性成果（含新见解、新观点、方法创新、技术创新、理论创新），并指出今后进一步在本研究方向进行研究工作的展望与设想。对所取得的创新性成果应注意从定性和定量两方面给出科学、准确的评价，分（1）、（2）、（3）…条列出，宜用“提出了”、“建立了”等词叙述。

## 参考文献



作者签名: \_\_\_\_\_ 日期: \_\_\_\_\_ 年 \_\_\_\_\_ 月 \_\_\_\_\_ 日

作者签名: \_\_\_\_\_ 日期: \_\_\_\_\_ 年 \_\_\_\_\_ 月 \_\_\_\_\_ 日

导师签名: \_\_\_\_\_ 日期: \_\_\_\_\_ 年 \_\_\_\_\_ 月 \_\_\_\_\_ 日

## 致 谢

衷心感谢导师 XXX 教授对本人的精心指导。他的言传身教将使我终生受益。

.....

感谢哈工大 L<sup>A</sup>T<sub>E</sub>X 论文模板 hiThesis !